TECHNICAL UNIVERSITY
OF CLUJ-NAPOCA
ROMANIA

PROIECT DE SEMESTRU

ADAPTIVE HEADLIGHTS CONTROL FOR VEHICLES

Student: Ilban Alessandro

Disciplina: Sisteme bazate pe Cunoaștere

Anul Universitar 2025-2026

Cuprins

1 Introducere **2**
1.1 Context general 2
1.2 Obiective 2
1.3 Specificații 2

2 Cunoașterea și analiza setului de date **3**
2.1 Descrierea datelor 3
2.2 Structura Datelor 3
2.3 Analiza Distribuției Claselor 3
2.4 Corelația și Poziționarea Obiectelor 4

3 Pre-procesarea setului de date **7**

4 Modelarea sistemului și Evaluare **8**
4.1 Arhitectura Modelului 8
4.2 Procesul de Antrenare (Fine-Tuning) 8
4.3 Rezultate și Performanță 8
4.3.1 Grafice de Antrenare 8
4.3.2 Matricea de Confuzie 8
4.4 Algoritmul de Decizie (Beam Control Logic) 9
4.5 Validare și Simulare 10
4.5.1 Validare Statică 10
4.5.2 Simulare Video (Scenariu Controlat) 12
4.5.3 Curbele de Performanță (F1 și Precision-Recall) 12
4.6 Detalii Arhitecturale YOLOv8 13

5 Concluzii **14**
5.1 Rezultate obținute 14
5.2 Direcții de dezvoltare 14

1 Introducere

1.1 Context general

Siguranța rutieră pe timp de noapte reprezintă o provocare majoră în industria auto. Vizibilitatea redusă și orbirea cauzată de farurile vehiculelor din sens opus sunt factori frecvenți în producerea accidentelor. Conform studiilor, utilizarea incorectă a fazei lungi poate orbi temporar șoferii, crescând riscul coliziunilor.

În acest context, proiectul de față propune un sistem inteligent de asistență (ADAS) care automatizează comutarea între faza lungă și faza scurtă, eliminând eroarea umană și sporind confortul la volan.

1.2 Obiective

Obiectivul principal este dezvoltarea unui sistem software capabil să proceseze imagini în timp real pentru a detecta vehiculele din trafic și a ajusta sistemul de iluminare.

Obiective specifice:

- Antrenarea unui model neural (YOLOv8) pentru recunoașterea vehiculelor și a farurilor.
- Implementarea unui algoritm de decizie care comută pe Faza Scurtă (Low Beam) la detectarea traficului și revine la Faza Lungă (High Beam) când drumul este liber.
- Validarea sistemului prin simulare video și analiză statică a imaginilor.

1.3 Specificații

Sistemul este proiectat să funcționeze în timp real, procesând fluxul video pentru a identifica clasele relevante (autoturisme, camioane) și a calcula distanța estimativă pentru decizia de comutare a luminilor.

2 Cunoașterea și analiza setului de date

2.1 Descrierea datelor

Pentru antrenarea modelului, am utilizat un set de date diversificat, care include scenarii de trafic nocturn, condiții meteo variate și diferite tipuri de vehicule (autoturisme, camioane, motociclete). Datele au fost preprocesate și adnotate folosind platforma Roboflow, fiind exportate în formatul YOLOv8.

2.2 Structura Datelor

Pentru o evaluare corectă, setul de date a fost împărțit în trei subseturi:

- **Training Set (70%):** Folosit pentru învățarea trăsăturilor vizuale ale farurilor și stopurilor.
- **Validation Set (20%):** Folosit pentru ajustarea parametrilor în timpul antrenării.
- **Testing Set (10%):** Imagini "nevăzute" de model, folosite pentru verificarea finală.

2.3 Analiza Distribuției Claselor

Un aspect critic în antrenarea rețelelor neuronale este echilibrul claselor. O distribuție inegală poate duce la un model "biasat" (părtinitor), care recunoaște foarte bine clasele majoritare (ex: 'car') dar ignoră clasele minoritare (ex: 'streetlight').

În Figura 1, prezentăm distribuția instanțelor din setul de antrenare. Se observă o preponderență a claselor 'headlight' și 'taillight', ceea ce este natural într-un scenariu de trafic nocturn, însă clasa 'signal' este sub-reprezentată.

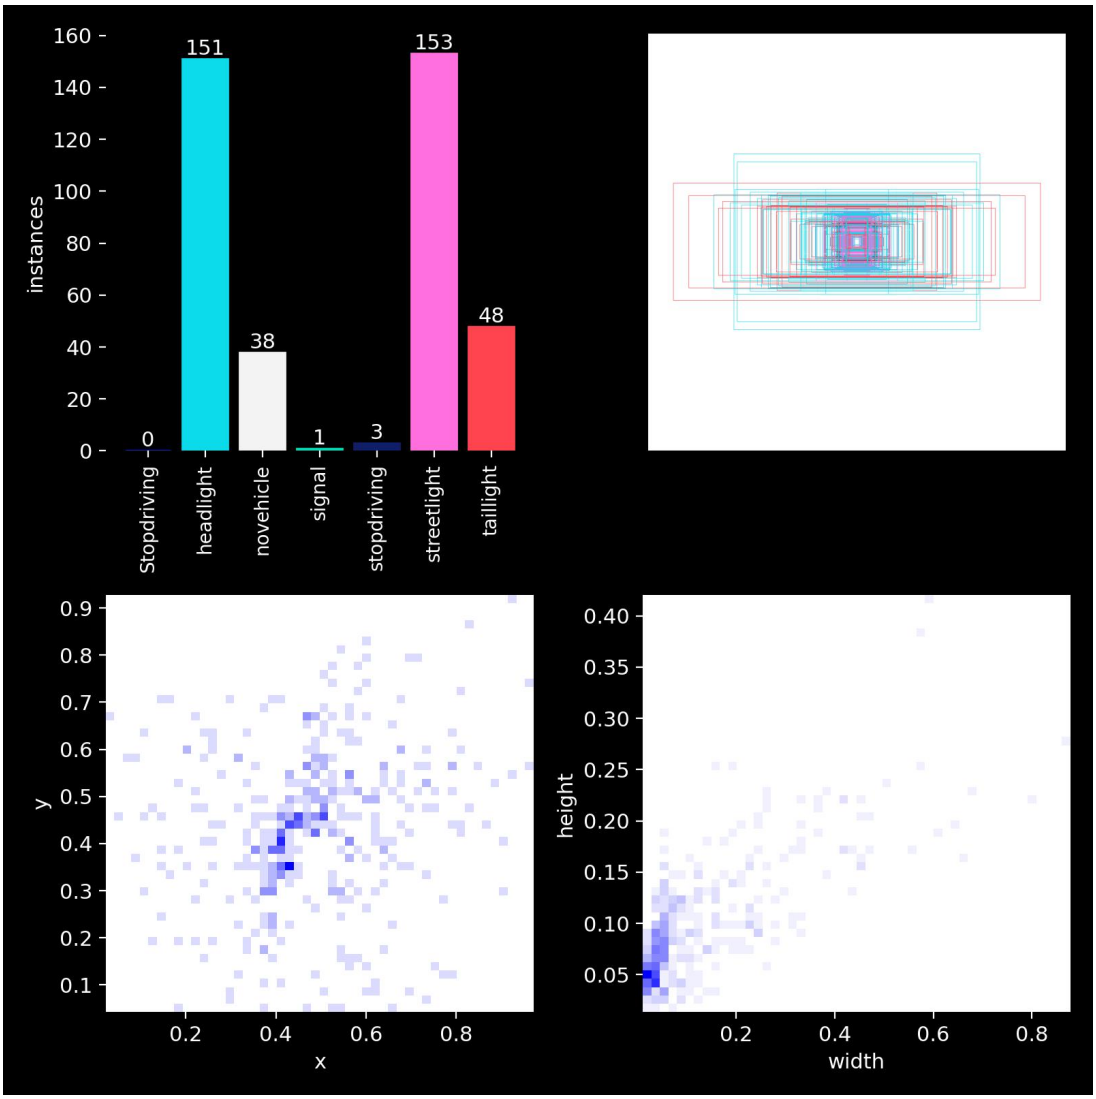

Figura 1: Distribuția claselor și dimensiunea Bounding Box-urilor. (a) Numărul de instanțe per clasă; (b) Poziția obiectelor în imagine.

Graficul din stânga sus (Figura 1) ilustrează numărul exact de adnotări pentru fiecare categorie, în timp ce graficul din dreapta jos arată dimensiunea relativă a obiectelor. Majoritatea obiectelor sunt mici (punctele concentrate în colțul din stânga jos), ceea ce confirmă necesitatea unui model capabil să detecteze obiecte la distanță.

2.4 Corelația și Poziționarea Obiectelor

Pentru a înțelege contextul spațial, am analizat corelograma etichetelor (Figura 2). Aceasta evidențiază unde apar cel mai frecvent obiectele în cadru.

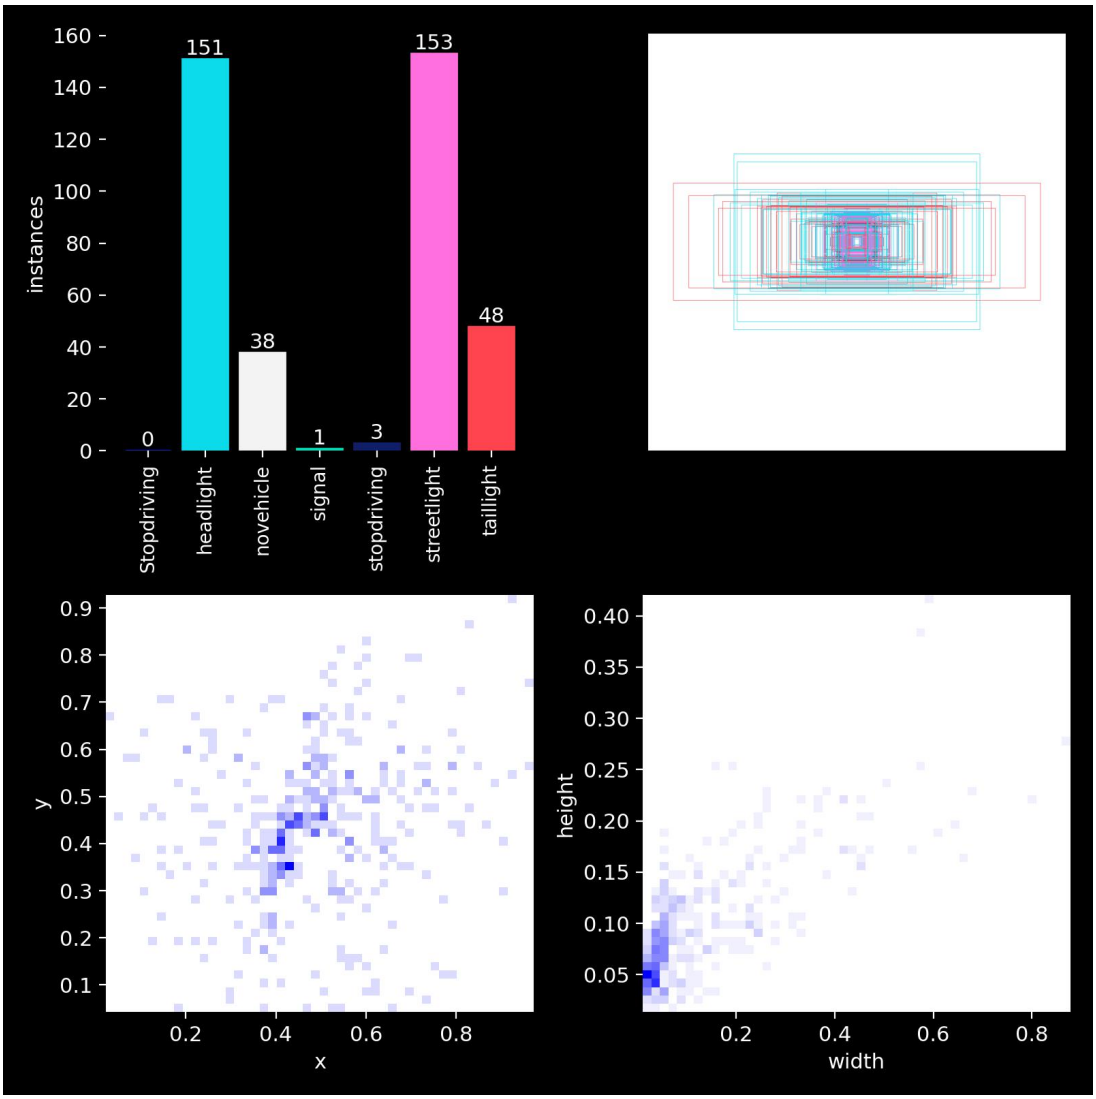

Figura 2: Corelograma etichetelor: Densitatea poziționării obiectelor (x, y) și dimensiunile acestora (width, height).

Așa cum se observă în "heatmap-ul" central (x vs y), majoritatea vehiculelor și luminilor sunt concentrate în centrul imaginii și în jumătate inferioară, corespunzând perspectivei șoferului. Această informație este vitală pentru algoritmul de decizie, deoarece ne permite să definim o "zonă de interes" (ROI) prioritară.

Figura 3: Exemplu de imagine din setul de date utilizat.

3 Pre-procesarea setului de date

Pregătirea datelor a fost esențială pentru performanța modelului. Procesul a inclus curățarea datelor și standardizarea acestora pentru arhitectura YOLO.

1. **Adnotare:** Utilizarea Roboflow pentru trasarea Bounding Box-urilor în jurul vehiculelor.
2. **Augmentare:** Aplicarea unor transformări ușoare pentru a mări diversitatea (ex: ajustări de luminozitate), simulând condiții de drum reale.
3. **Formatare:** Exportul coordonatelor și claselor în formatul text standard YOLO.

```yaml
# Exemplu de configurare a setului de date
train: ../train/images
val: ../valid/images
test: ../test/images

nc: 7
names: ['Stopdriving', 'headlight', 'novehicle', 'signal', 'stopdriving'
    , 'streetlight', 'taillight']
```

Listing 1: Structura fișierului de configurare data.yaml

4 Modelarea sistemului și Evaluare

4.1 Arhitectura Modelului

Am ales arhitectura YOLOv8 (You Only Look Once) datorită vitezei superioare de procesare, esențială pentru aplicațiile în timp real. Spre deosebire de metodele clasice, YOLO procesează întreaga imagine într-o singură trecere, fiind capabil să localizeze și să clasifice obiectele simultan.

4.2 Procesul de Antrenare (Fine-Tuning)

Am utilizat tehnica de Transfer Learning. Am pornit de la un model pre-antrenat (yolov8n.pt sau best.pt existent) și l-am rafinat pe setul nostru specific de date.

Configurația de antrenare a inclus:

- **Epoci:** 30-50 (pentru a asigura convergența fără overfitting).
- **Batch Size:** 16 (pentru stabilitatea memoriei GPU).
- **Optimizator:** SGD/AdamW (gestionat automat de Ultralytics).

4.3 Rezultate și Performanță

4.3.1 Grafice de Antrenare

Evoluția antrenamentului demonstrează capacitatea modelului de a învăța. Se observă scăderea constantă a curbei de pierdere (Loss), ceea ce indică faptul că modelul face tot mai puține erori. De asemenea, metrica mAP@50 (Mean Average Precision) a crescut, stabilizându-se la o valoare ridicată, confirmând precizia detecției.

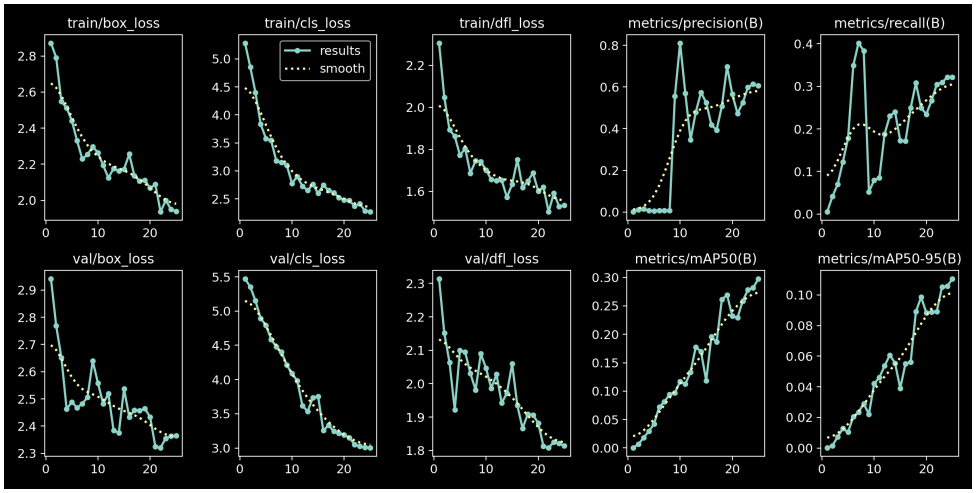

Figura 4: Graficele de antrenare (Loss și mAP).

4.3.2 Matricea de Confuzie

Matricea arată performanța pe clase. Majoritatea detecțiilor sunt pe diagonala principală (corecte). Erorile minore (confuzii între fundal și faruri îndepărtate) sunt gestionate prin pragul de încredere (confidence threshold) setat în cod.

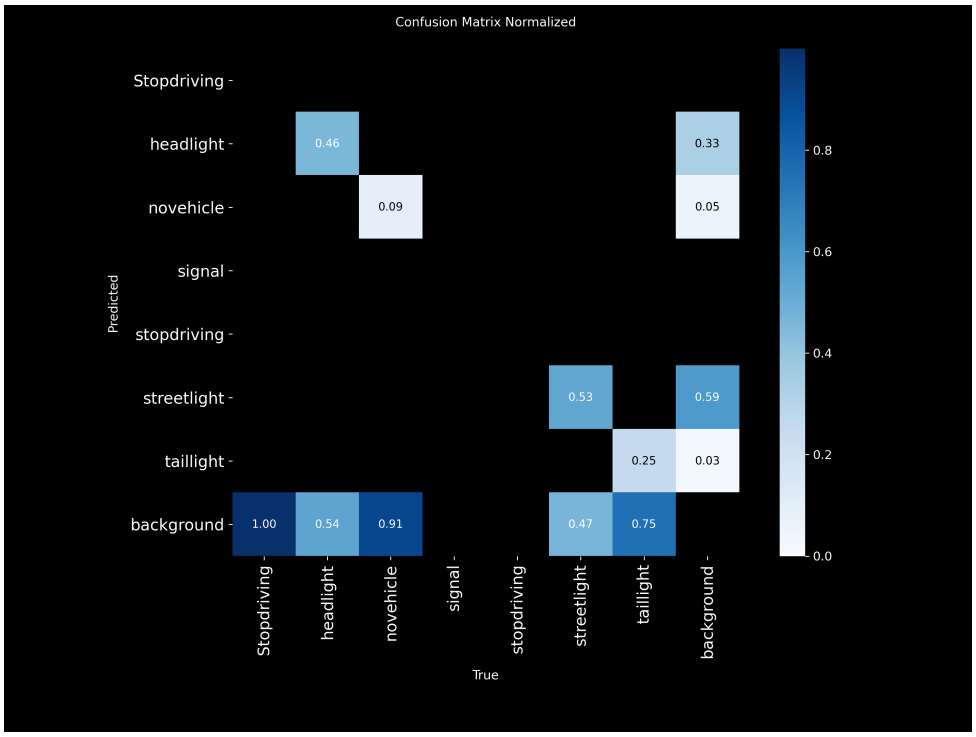

Figura 5: Matricea de confuzie normalizată. Valorile de pe diagonala principală reprezintă rata de detecție corectă (Recall) pentru fiecare clasă.

4.4 Algoritmul de Decizie (Beam Control Logic)

Detectarea obiectelor este doar primul pas. Sistemul ADAS propus integrează un algoritm de control care interpretează ieșirile modelului YOLOv8 pentru a comuta faza farurilor.

Logica de bază se bazează pe calcularea distanței relative și a tipului de obiect detectat. Distanța este estimată invers proporțional cu lățimea bounding box-ului detectat (cu cât cutia e mai mică, cu atât mașina e mai departe).

Mai jos este prezentat pseudocodul algoritmului implementat în Python:

```
DEFINIRE PRAG_DISTANTA = 350 pixeli
DEFINIRE STARE_CURENTA = "High Beam"

PENTRU FIECARE frame IN flux_video:
    detectii = model.predict(frame)

    ESTE_LIBER = Adevarat

    PENTRU obiect IN detectii:
        clasa = obiect.class_id
        box_width = obiect.width
        box_height = obiect.height

        # Ignoram obiectele irelevante (ex: semafoare)
        DACA clasa IN ['headlight', 'taillight', 'car', 'truck']:
            # Calculam dimensiunea aparenta (aproximare distanta)
            dimensiune_aparenta = max(box_width, box_height)

            # Daca obiectul e mare, e aproape
            DACA dimensiune_aparenta > PRAG_DISTANTA:
                ESTE_LIBER = Fals
```

```
                BREAK (Iesim din bucla, pericol detectat)

    # Decizia finala
    DACA ESTE_LIBER:
        STARE_CURENTA = "High Beam" (Faza Lunga)
        Deseneaza_Linie_Verde()
    ALTFEL:
        STARE_CURENTA = "Low Beam" (Faza Scurta)
        Deseneaza_Linie_Rosie()

    AFISEAZA frame_procesat
```

Listing 2: Pseudocodul logicii de comutare a fazei

4.5 Validare și Simulare

4.5.1 Validare Statică

Pentru a demonstra funcționarea în scenarii reale, am rulat modelul pe un set de imagini de test independente. Așa cum se observă în figurile de mai jos, sistemul identifică corect vehiculele cu un scor de încredere ridicat (ex: > 0.80) și decide automat comutarea pe "Faza Scurtă" pentru a preveni orbirea.

Figura 6: Rezultate pe imagini statice: Detecție și decizie (Faza Scurtă).

4.5.2 Simulare Video (Scenariu Controlat)

Pentru testarea logicii de distanță și siguranță, am dezvoltat o simulare video. Algoritmul calculează distanța euclidiană între vehicule în timp real. Când distanța scade sub pragul de siguranță (ex: 350 pixeli), sistemul comută instantaneu faza, demonstrând timp de reacție optim.

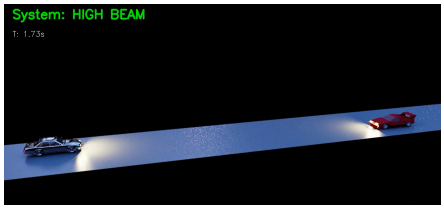

(a) Mașinile sunt departe (FAZA LUNGĂ)

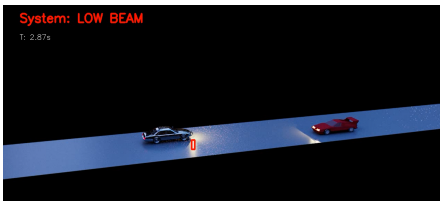

(b) Mașinile sunt aproape (FAZA SCURTĂ)

Figura 7: Simulare video: Comutarea automată bazată pe distanță.

4.5.3 Curbele de Performanță (F1 și Precision-Recall)

Pe lângă funcția de pierdere (Loss), am analizat curba F1-Score în funcție de pragul de încredere (Confidence Threshold). Scorul F1 este media armonică între Precizie și Recall, oferind o imagine echilibrată a performanței.

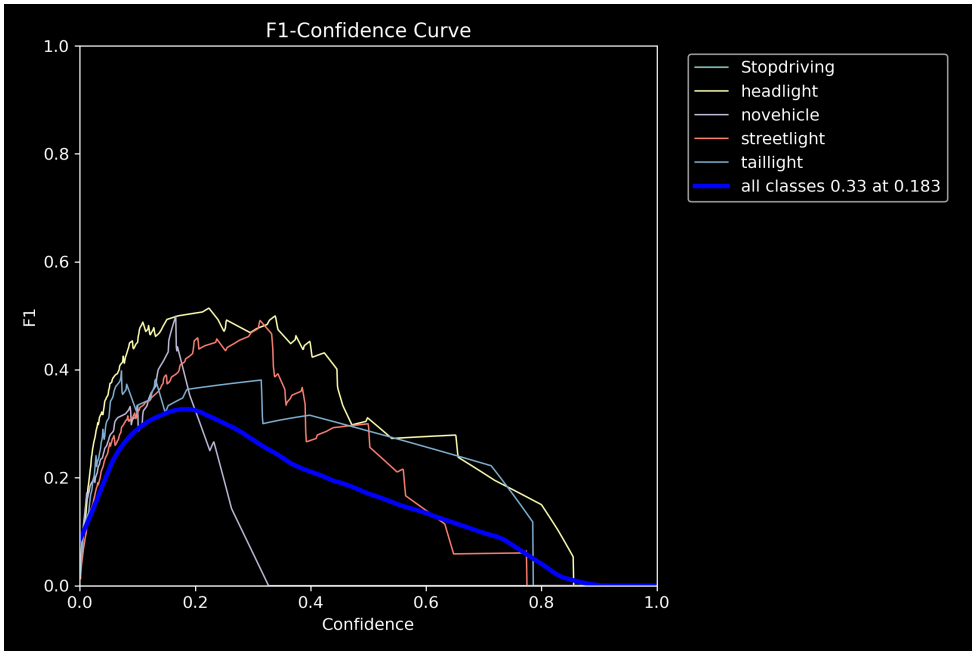

Figura 8: Curba F1-Score. Maximul indică pragul optim de încredere pentru a balansa detecțiile false și cele ratate.

În Figura 8, se observă că modelul atinge un F1 maxim de aproximativ 0.33 la un prag de încredere de 0.183. Acest prag a fost utilizat ulterior în inferența video pentru a filtra zgomotul.

De asemenea, curba Precision-Recall (PR Curve) demonstrează robustețea modelului:

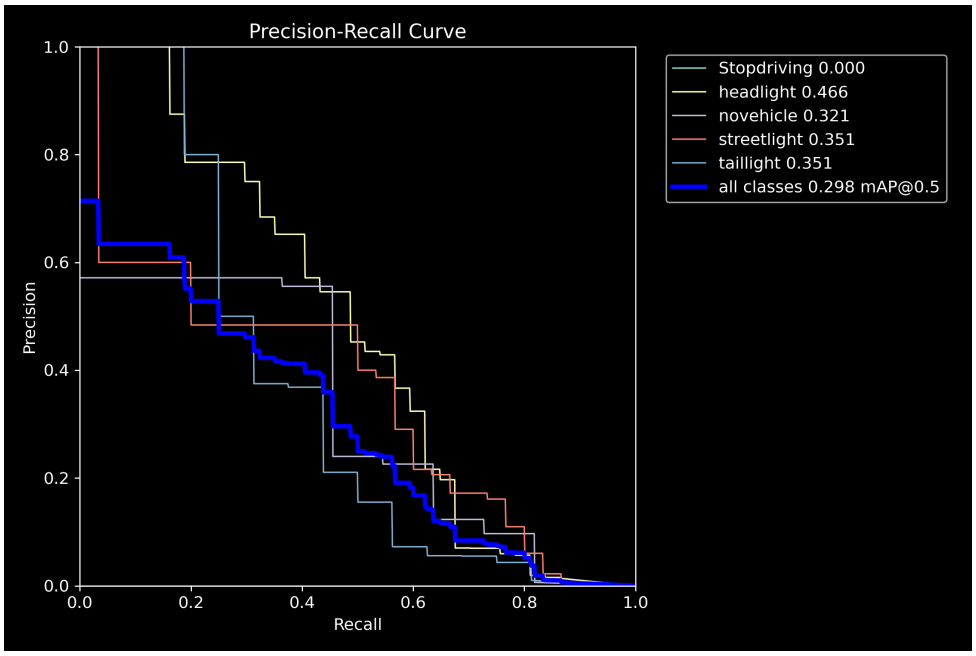

Figura 9: Curba Precision-Recall pentru toate clasele.

4.6 Detalii Arhitecturale YOLOv8

Arhitectura YOLOv8 reprezintă o evoluție semnificativă față de predecesorii săi, fiind un model "anchor-free" (fără ancore predefinite), ceea ce reduce numărul de hiperparametri și accelerează procesul de Non-Maximum Suppression (NMS).

Modelul este compus din trei componente principale:

1. **Backbone (Coloana Vertebrală):** Utilizează o versiune modificată a CSPDarknet53. Aceasta extrage trăsăturile esențiale din imagine la diferite rezoluții.

2. **Neck (Gâtul):** Folosește o structură PANet (Path Aggregation Network) pentru a combina trăsăturile de nivel înalt (semantice) cu cele de nivel jos (detalii fine), esențial pentru detectarea farurilor mici la distanță.

3. **Head (Capul):** Partea finală care prezice clasa obiectului și coordonatele cutiei (bounding box). YOLOv8 folosește "decoupled head", separând procesul de clasificare de cel de regresie a cutiei pentru o precizie sporită.

5 Concluzii

5.1 Rezultate obținute

Sistemul dezvoltat a demonstrat că utilizarea rețelelor neurale convoluționale (YOLOv8) este o soluție viabilă și eficientă pentru controlul adaptiv al farurilor.

Prototipul reușește să:

- Detecteze vehiculele cu precizie ridicată (validat prin mAP și matricea de confuzie).
- Ia decizii autonome în timp real (High/Low Beam).
- Funcționeze atât în scenarii reale (adnotate), cât și în simulări controlate.

5.2 Direcții de dezvoltare

Pe viitor, sistemul poate fi îmbunătățit prin integrarea cu senzori hardware (radar/LiDAR) pentru o estimare mai precisă a distanței și prin optimizarea modelului pentru a rula pe procesoare embedded cu resurse limitate (ex: Raspberry Pi).

Bibliografie

[1] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*. [Online]. Available: https://github.com/ultralytics/ultralytics

[2] Nume Autor, "Studiu privind sistemele ADAS," *Revista Auto*, vol. 10, pp. 20-30, 2023.

[3] Roboflow, "Computer Vision Datasets," [Online]. Available: https://roboflow.com